

Identificazione di Sistemi Dinamici Non Lineari: Analisi Comparativa su Benchmark Industriale KUKA

Marco Conte¹, Francesco Iannarone¹, and Andrea Nuara¹

¹Dipartimento di Automatica e Informatica, Politecnico di Torino

Sommario—L'identificazione accurata della dinamica dei manipolatori industriali ad alto carico è fondamentale per lo sviluppo di schemi di controllo avanzati e per il monitoraggio dello stato della macchina. Tuttavia, la modellazione fisica classica si scontra spesso con non linearità strutturali complesse e difficilmente parametrizzabili, quali attriti dissipativi e giochi meccanici (*backlash*). Questo lavoro presenta un'analisi comparativa basata interamente sui dati (*black-box*) per l'identificazione della dinamica di un robot industriale KUKA KR300, confrontando tre diverse architetture neurali: un modello autoregressivo con ingressi esogeni (NNARX), una rete neurale ricorrente standard (RNN) e una rete a cancelli *Gated Recurrent Unit* (GRU). Le prestazioni sono studiate sia nel task di dinamica diretta ($\tau \rightarrow q$), valutato nella severa modalità di simulazione libera (*free-run*), sia nel task di dinamica inversa ($q \rightarrow \tau$). I risultati sperimentali evidenziano che, mentre la RNN classica fallisce a causa del fenomeno del *vanishing gradient*, l'architettura GRU e il modello NNARX superano nettamente la baseline lineare. In particolare, la GRU incrementa l'accuratezza nel task diretto portando il coefficiente R^2 oltre il 50%, mentre nel task inverso entrambi i modelli superano l'83% di R^2 . L'introduzione di tecniche come lo *Scheduled Sampling* nell'architettura NNARX dimostra inoltre un'elevata robustezza all'accumulo ricorsivo dell'errore, delineando soluzioni promettenti per il disaccoppiamento computazionale dei giunti nei futuri sistemi di controllo robotico.

I. INTRODUZIONE

L'identificazione dei sistemi (*System Identification* - SI) rappresenta un pilastro fondamentale dell'ingegneria dell'automazione e della robotica industriale. Il suo obiettivo primario è la costruzione di modelli matematici accurati capaci di descrivere il comportamento dinamico di un sistema reale partendo esclusivamente da dati sperimentali di ingresso e uscita.

Nei manipolatori industriali moderni, la necessità di incrementare la velocità operativa e la precisione del posizionamento sotto carichi gravosi ha reso i modelli dinamici, basati esclusivamente sulle equazioni di Newton-Eulero o sui parametri di Denavit-Hartenberg, insufficienti per scopi di controllo avanzato e monitoraggio dello stato della macchina.

A. Lo Stato dell'Arte e i suoi Limiti

La modellazione classica della dinamica dei robot (*White-Box modeling*) si scontra con fenomeni fisici complessi che risultano difficilmente parametrizzabili a priori. Queste non linearità strutturali possono essere di vario tipo:

- **Attrito non lineare:** Fenomeni di attrito statico (*stiction*), attrito di Coulomb e viscosità termodipendente all'interno dei riduttori.
- **Elasticità e gioco meccanico:** Effetti di *backlash* e cedimenti strutturali flessibili, particolarmente accentuati in robot industriali ad alto carico cinematico.
- **Accoppiamenti inerziali:** Forze centrifughe e di Coriolis che variano in modo fortemente non lineare in funzione della configurazione geometrica dello spazio dei giunti.

Per superare i limiti dei modelli fisici, la letteratura scientifica si è orientata verso approcci basati interamente sui dati (*Black-Box modeling*). Storicamente, i modelli auto-regressivi lineari (come i modelli ARX classici) hanno dominato la scena grazie alla loro semplicità computazionale e alle garanzie di convergenza dell'algoritmo dei minimi quadrati. Tuttavia, l'incapacità intrinseca dei modelli lineari di mappare le forti non linearità geometriche dei manipolatori rigidi ha spinto la ricerca moderna verso il paradigma del *Deep Learning*.

Come evidenziato da Goodfellow et al. [3], le reti neurali artificiali agiscono come approssimatori universali di funzioni. Nel contesto temporale e sequenziale, le reti neurali ricorrenti (RNN) standard introducono una memoria interna latente ideale per descrivere i sistemi dinamici. Ciononostante, l'addestramento delle RNN su traiettorie estese è strutturalmente afflitto dal problema della scomparsa del gradiente (*vanishing gradient*).

Per risolvere tale criticità, l'introduzione di architetture a cancelli (*gated*) come le *Gated Recurrent Units* (GRU), formalizzate da Cho et al. [4], ha permesso di preservare le dipendenze temporali a lungo termine. Le GRU offrono inoltre un compromesso computazionale ottimale rispetto alle strutture LSTM (*Long Short-Term Memory*), garantendo prestazioni analoghe a fronte di un minor numero di parametri interni e tempi di addestramento ridotti.

B. L'Esperimento e Contributo del Lavoro

Questo studio analizza e confronta criticamente l'efficacia di tre diverse architetture neurali (NNARX, RNN e GRU) nell'identificazione della dinamica di un manipolatore ad alto carico, operando sulle traiettorie del benchmark industriale KUKA KR300 proposto da Weigand et al. [1].

L'indagine si articola attraverso due compiti speculari di identificazione, fondamentali per comprendere le capacità pre-

dittive delle reti e la loro applicabilità industriale: la dinamica diretta e la dinamica inversa.

1) *Dinamica Diretta (Forward Dynamics)*: La dinamica diretta descrive l'evoluzione temporale dello stato del robot a seguito delle sollecitazioni impresse dagli attuatori. Il modello neurale apprende la mappatura funzionale:

$$\tau(t) \longrightarrow q(t) \quad (1)$$

dove l'input è costituito dal vettore delle coppie motrici applicate ai giunti $\tau \in \mathbb{R}^6$, mentre l'output stimato è il vettore delle posizioni angolari risultanti $q \in \mathbb{R}^6$ (e le relative velocità $\dot{q}$).

La principale criticità operativa risiede nella modalità di simulazione libera (*free-run simulation*): l'uscita predetta dalla rete al passo t viene reintrodotta ricorsivamente come ingresso per il passo $t + 1$. Questo framework esaspera l'accumulo di piccoli errori locali, provocando fenomeni di deriva (*drifting*) della traiettoria che mettono a dura prova la stabilità asintotica dei modelli.

2) *Dinamica Inversa (Inverse Dynamics)*: La dinamica inversa risolve il problema opposto, calcolando le forze e le coppie necessarie per indurre un determinato profilo cinematico nello spazio. La rete apprende la mappatura:

$$\{q(t), \dot{q}(t), \ddot{q}(t)\} \longrightarrow \tau(t) \quad (2)$$

In questo caso, lo stato cinematico completo del robot (posizioni, velocità e accelerazioni dei giunti) costituisce l'input del sistema, mentre il vettore delle coppie stimate $\tau \in \mathbb{R}^6$ rappresenta l'output.

Poiché gli ingressi cinematici sono forniti direttamente dal dataset di benchmark e non dipendono ricorsivamente dalle uscite precedenti della rete (*one-step-ahead prediction*), questo task risulta numericamente molto più stabile. Esso riveste una fondamentale importanza applicativa, in quanto costituisce il nucleo algoritmico dei moderni sistemi di controllo a coppia calcolata (*computed-torque control*).

C. Architettura Cinematica e Struttura Meccanica

Il KUKA KR300 R2500 ultra SE è un manipolatore industriale ad asse articolato caratterizzato da una catena cinematica aperta di tipo antropomorfo con 6 gradi di libertà (DoF), tutti azionati da servomotori AC accoppiati a riduttori epicicloidali o *Harmonic Drive* ad alta rigidità torsionale.

La struttura meccanica può essere idealmente suddivisa in due macro-blocchi funzionali indipendenti, i cui comportamenti dinamici presentano costanti di tempo e scale inerziali profondamente distinte:

- **Struttura di Posizionamento (Giunti 1, 2, 3)**: Costituisce la base portante e la struttura a portale del robot. Il Giunto 1 (A1) consente la rotazione dell'intera colonna attorno all'asse verticale z zero. Il Giunto 2 (A2) regola l'inclinazione del braccio inferiore (*Link arm*), supportando il carico gravitazionale principale anche grazie all'ausilio di un compensatore idropneumatico o a molla montato posteriormente. Il Giunto 3 (A3) comanda l'estensione del braccio superiore (*Arm*). Questi tre assi

muovono le masse più significative del sistema (oltre 1100 kg totali) e sono soggetti a forti variazioni del tensore d'inerzia in funzione della posa operativa.

- **Polso Sferico di Orientamento (Giunti 4, 5, 6)**: Configurato come un polso sferico in linea (*In-line wrist*), in cui i tre assi di rotazione si intersecano in un unico centro geometrico comune. Il Giunto 4 (A4) effettua la torsione del braccio, il Giunto 5 (A5) controlla il beccheggio dell'organo terminale (*pitch*) e il Giunto 6 (A6) gestisce la rotazione finale della flangia di attacco dello strumento (*Spindle*). Questa terna presenta un'inerzia ridotta ma è soggetta ad accelerazioni angolari estremamente elevate e risente degli accoppiamenti dinamici derivanti dai movimenti dei giunti principali.

Dato questo layout strutturale, la modellazione cinematica viene tradizionalmente formalizzata secondo la convenzione di Denavit-Hartenberg (DH), assegnando una terna di riferimento locale $O_i - X_i Y_i Z_i$ a ciascun braccio del manipolatore. L'interazione dinamica reciproca tra la struttura di posizionamento ad alta inerzia e il polso agile costituisce la principale causa di instabilità numerica riscontrata nei modelli di identificazione monolitici standard, giustificando la necessità dell'approccio disaccoppiato implementato in questo lavoro.

II. DATASET E CONFIGURAZIONE DEI DATI

Il lavoro si basa sul benchmark industriale proposto da Weigand et al. [1], che fornisce traiettorie di movimento complete per l'identificazione black-box di un manipolatore a 6 gradi di libertà (DoF). Il dataset è costituito da 36 traiettorie distinte, ciascuna della durata di 60.6 secondi e ripetuta due volte per valutarne la ripetibilità, per un totale di circa 73 minuti di telemetria. I dati sono suddivisi in:

- **Training Set**: 33 traiettorie (*Figure 1 e 2*) (circa 67 minuti, 39988 campioni), utilizzato per l'addestramento e l'ottimizzazione dell'architettura neurale.
- **Test Set**: 3 traiettorie indipendenti (*Figure 3 e 4*) (circa 6 minuti, 3636 campioni), riservato alla validazione finale delle performance.

I dati originali contengono misure non filtrate e ad alta frequenza con tempo di campionamento di 4 ms (250 Hz), ma le limitazioni fisiche legate alla rigidità e all'elasticità dei riduttori assorbono intrinsecamente le frequenze più elevate. Pertanto, si è scelto di operare direttamente sui dati pre-elaborati per un confronto diretto con le baseline lineari fornite dalla letteratura. Tale pre-elaborazione prevede l'applicazione di un filtro passa-basso (frequenza di taglio a 2 Hz) e un successivo sottocampionamento con frequenza di campionamento di 10 Hz (periodo $\Delta t = 100$ ms).

Al fine di addestrare i modelli per i due distinti task, i dati sono stati strutturati in base al problema. Nella dinamica diretta (*Forward Task*) il modello predice la cinematica a partire dallo sforzo: l'ingresso U è un vettore a 6 dimensioni contenente le coppie motrici (Nm) applicate ai giunti, mentre il target Y è la posizione angolare (deg) effettiva misurata dagli encoder. Nella dinamica inversa (*Inverse Task*) il modello




Figura 1. Coppie motrici misurate in Nm utilizzate come dati di addestramento. Ogni riga corrisponde a una coppia.




Figura 2. Posizioni dei joint misurate in gradi come dati di addestramento. Ogni riga corrisponde a un joint.

stima le coppie necessarie a inseguire una traiettoria: l'ingresso Y in questo caso è espanso a 18 dimensioni, includendo posizioni, velocità e accelerazioni per i 6 giunti. Il target U è rappresentato dalle coppie motrici.

Per agevolare la convergenza dell'ottimizzatore, i segnali sono stati sottoposti a standardizzazione statistica (Z-score). Infine, le serie temporali continue sono state frammentate in finestre sequenziali di $L = 120$ passi per non fornire al modello tutti i sample contemporaneamente.

III. METODI

Per affrontare la complessità della dinamica del KU-KA KR300 e prevenire fenomeni di instabilità numerica o overfitting, il processo di addestramento è stato integrato con protocolli rigorosi di regolarizzazione e ottimizzazione euristica.

A. Normalizzazione e Preprocessing

Data la natura eterogenea delle grandezze fisiche (coppie in Nm e posizioni in radianti), tutti i segnali sono stati sottoposti a una normalizzazione *Min-Max* nell'intervallo $[-1, 1]$.




Figura 3. Coppie motrici misurate in Nm utilizzate come dati di addestramento. Ogni riga corrisponde a una coppia.




Figura 4. Coppie motrici misurate in Nm utilizzate come dati di addestramento. Ogni riga corrisponde a una coppia.

Questo passaggio, visibile nell'utilizzo del `MinMaxScaler` nei codici sorgente, è essenziale per uniformare la topologia della funzione di costo e facilitare il lavoro dell'ottimizzatore Adam, evitando che i giunti con escursioni maggiori dominino il gradiente.

B. Algoritmo di Early Stopping

L'overfitting rappresenta un rischio concreto nelle reti ricorrenti profonde, dove la capacità di memorizzazione può portare a una scarsa generalizzazione su traiettorie non viste. È stata quindi implementata una classe `EarlyStopping` dedicata, che monitora la loss sul set di validazione al termine di ogni epoca.

- **Patience:** Il processo di addestramento viene interrotto se la loss di validazione non mostra miglioramenti significativi per un numero prestabilito di epoche.
- **Checkpointing:** Al termine dell'esecuzione, il modello finale non corrisponde all'ultima epoca, bensì allo stato che ha fatto registrare il minimo errore di validazione assoluto.

C. Iperparametri

Per garantire la riproducibilità degli esperimenti, la selezione degli iperparametri è stata condotta attraverso una ricerca empirica volta a massimizzare le capacità di generalizzazione del modello.

Il criterio matematico utilizzato per la selezione della configurazione ottimale è stato il raggiungimento del minimo della *Training Loss* considerando anche la *Validation Loss*.

Per mitigare la dipendenza dei risultati dall'inizializzazione casuale dei pesi, ogni singola combinazione di iperparametri è stata validata all'interno di un framework *Multi-Start* composto da 5 run indipendenti. La configurazione finale riportata è quella appartenente alla run che ha minimizzato l'errore di validazione.

Durante la fase di sviluppo, le variabili iperparametriche sono state modulate all'interno di specifici range di indagine.

L'ottimizzatore utilizzato per tutti gli esperimenti è Adam. Di seguito sono riportati i valori testati e le scelte finali:

- **Dimensione dello Stato Nascosto (*Hidden Dim*):** Esplorata nel set $\{32, 64, 128\}$. Si è osservato che valori superiori a 64 portavano a un rapido overfitting, spingendo la rete a memorizzare il rumore ad alta frequenza dei sensori. Il valore finale selezionato è stato **64**.
- **Tasso di Apprendimento (*Learning Rate*):** Valutato nel range logaritmico $[10^{-3}, 10^{-2}]$. Per il NNARX, valori troppo alti causavano instabilità e l'esplosione dei gradienti nelle prime epoche a causa del feedback. Il parametro finale, quindi, è stato fissato a **0.002** per il modello NNARX e **0.01** per la GRU e per la RNN.
- **Dimensione del Batch (*Batch Size*):** Testata nel set $\{64, 128, 256\}$. La dimensione di **128** sequenze ha fornito il miglior compromesso hardware-software, garantendo velocità di convergenza e un'adeguata stocasticità nella discesa del gradiente.
- **Decadimento dello Scheduled Sampling (*Teacher Forcing*):** La percentuale di epoche dedicate al decadimento nel NNARX è stata variata tra il 30%, 50% e 70% del training totale. Il **30%** si è rivelato il valore critico e ottimale per evitare il collasso iniziale dei pesi, lasciando alla rete un numero di epoche sufficiente per stabilizzare autonomamente il ciclo autoregressivo.
- **Criterio di Arresto (*Early Stopping*):** Il numero massimo di epoche è stato limitato a **200**. La *patience* dell'Early Stopping è stata testata tra $\{20, 30, 40\}$. Il valore finale di **40** epoche è stato adottato per assorbire le oscillazioni della *Loss* in *Closed-Loop* nell'Inverse Task, senza interrompere il raggiungimento del regime ad alta frequenza.

D. Architetture utilizzate

All'interno di questo studio sono state utilizzate e confrontate diverse architetture: dalla classica RNN, passando per la NNARX, per poi arrivare all'architettura GRU. La scelta dell'architettura neurale è l'elemento determinante nella capacità di un modello di catturare le dinamiche temporali di un sistema complesso come il KUKA KR300. In questa sezione vengono analizzati i tre paradigmi fondamentali utilizzati nel confronto: NNARX, RNN e GRU.

- **Neural Network ARX (NNARX)** Il modello *Neural Network Auto-Regressive with Exogenous input* (NNARX) rappresenta l'estensione non lineare del modello ARX classico. Si basa su una struttura a memoria esplicita, dove la dinamica del sistema viene fornita alla rete tramite vettori di campioni passati dell'ingresso (u) e dell'uscita (y).

Matematicamente, la predizione al tempo t è espressa come:

$$\hat{y}(t) = f_{MLP}(y(t-1), \dots, y(t-n_y), u(t-1), \dots, u(t-n_u)) \quad (3)$$

dove n_y e n_u sono gli ordini dei ritardi temporali (*tapped delay lines*).

- **Struttura:** Utilizza un percettore multistrato (MLP) che opera come un approssimatore statico di una funzione dinamica.

- **Vantaggi:** Presenta un'elevata stabilità durante l'addestramento e non soffre di problemi di gradiente legati alla ricorsività interna.
- **Limiti:** La capacità di memoria è rigidamente vincolata alla dimensione della finestra temporale scelta, rendendo difficile la cattura di dinamiche a lungo termine o derivate lente.

- **Recurrent Neural Networks (RNN)** Le reti neurali ricorrenti (RNN) introducono una memoria implicita tramite connessioni di feedback tra i neuroni. A differenza del NNARX, le RNN processano le informazioni in modo sequenziale, mantenendo uno stato interno latente h_t che funge da memoria sintetica dell'intera storia passata.

L'evoluzione dello stato è regolata dalla seguente equazione:

$$h_t = \sigma(W_{hh}h_{t-1} + W_{xh}x_t + b_h) \quad (4)$$

dove σ è una funzione di attivazione non lineare (tipicamente $\tanh$ o $ReLU$).

- **Caratteristica Core:** Lo stato nascosto permette di mappare sequenze di lunghezza arbitraria senza definire a priori il numero di ritardi.
- **Svantaggi:** Le RNN standard sono soggette al problema del *vanishing gradient*. Durante l'addestramento tramite *Backpropagation Through Time* (BPTT), il gradiente tende a svanire per sequenze lunghe, rendendo la rete incapace di correlare eventi distanti nel tempo.

- **Gated Recurrent Units (GRU)** Le *Gated Recurrent Units* (GRU) sono state introdotte per superare i limiti delle RNN semplici tramite meccanismi di *gating* che controllano il flusso informativo. Rispetto alle più complesse LSTM, le GRU offrono un compromesso ottimale tra prestazioni e costo computazionale.

L'architettura è governata da due gate principali:

- 1) **Update Gate (z_t):** Determina quanta parte dello stato precedente deve essere mantenuta nel tempo.
- 2) **Reset Gate (r_t):** Decide quanta parte dell'informazione passata debba essere ignorata prima di calcolare il nuovo candidato di stato.

Le equazioni che descrivono il meccanismo sono:

$$z_t = \sigma(W_z \cdot [h_{t-1}, x_t] + b_z) \quad (5)$$

$$r_t = \sigma(W_r \cdot [h_{t-1}, x_t] + b_r) \quad (6)$$

$$\tilde{h}_t = \tanh(W \cdot [r_t \odot h_{t-1}, x_t] + b) \quad (7)$$

$$h_t = (1 - z_t) \odot h_{t-1} + z_t \odot \tilde{h}_t \quad (8)$$

Grazie a questa struttura, le GRU sono in grado di preservare informazioni rilevanti per molti passi temporali, risultando l'architettura più performante per l'identificazione di sistemi industriali dove il rumore e le costanti di tempo elevate sono predominanti.

E. Metriche di Performance

Per quantificare l'accuratezza dei modelli e permettere un confronto rigoroso, sono stati selezionati tre indicatori statistici

suggeriti dal benchmark. Tali metriche valutano sia l'errore puntuale che la capacità di inseguimento della dinamica globale.

1) *Normalized Mean Squared Error (NMSE)*: L'errore quadratico medio normalizzato (NMSE) è stato adottato come funzione di costo primaria. La normalizzazione rende la metrica indipendente dalla scala dei dati, fondamentale per giunti con escursioni angolari molto diverse:

$$NRMSE_n = \sqrt{\frac{1}{K\sigma_{q,n}^2} \sum_{k=1}^K (q_{meas,n,k} - q_{est,n,k})^2} \quad (9)$$

dove $\sigma_{q,n}$ è la deviazione standard della posizione del giunto n .

2) *Best Fit Rate (BFR)*: Il *Best Fit Rate* esprime la qualità del fit in termini percentuali:

$$BFR(\%) = 100 \times \left(1 - \frac{\|q_{meas} - q_{est}\|_2}{\|q_{meas} - \bar{q}_{meas}\|_2}\right) \quad (10)$$

Un valore del 100% indica una corrispondenza perfetta. È una metrica particolarmente severa in modalità *free-run*, poiché riflette l'accumulo di errori di fase nel tempo.

3) *Coefficiente di Determinazione (R^2)*: Il coefficiente R^2 misura la proporzione di varianza dell'uscita spiegata dal modello:

$$R_n^2 = 100 \left(1 - \frac{\sum_{k=1}^K (q_{meas,n,k} - q_{est,n,k})^2}{\sum_{k=1}^K (q_{meas,n,k} - \bar{q}_{meas,n})^2}\right) \quad (11)$$

Un valore di R^2 prossimo a 100 indica che il modello cattura accuratamente la dinamica del sistema, distinguendola dal rumore o da una stima basata sulla sola media.

IV. ESPERIMENTI

A. Analisi dell'Overfitting e Limiti del Fine-Tuning

Un aspetto critico emerso durante la fase di ottimizzazione dei modelli riguarda il fenomeno dell'overfitting, particolarmente marcato nei tentativi di *fine-tuning* delle architetture più profonde. Nonostante l'utilizzo di tecniche di regolarizzazione, è stato osservato come un addestramento prolungato o una specializzazione eccessiva dei parametri portasse la rete a memorizzare il rumore intrinseco dei dati di training piuttosto che la dinamica sottostante del robot.

1) *Rischi del Fine-Tuning nelle GRU*: Durante la sperimentazione, abbiamo tentato di affinare i pesi dei modelli attraverso cicli di fine-tuning a basso learning rate. Tuttavia, come illustrato nella Fig. 5, l'analisi delle curve di apprendimento ha mostrato una divergenza netta: mentre la loss di addestramento continuava a decrescere asintoticamente, la loss di validazione mostrava un'inversione di tendenza (il cosiddetto "gomito" di overfitting) dopo poche epoche.

L'analisi del grafico conferma che per sistemi con dinamiche non lineari elevate e dati ad alta frequenza, un modello "più allenato" non coincide necessariamente con un modello "migliore".




Figura 5. Confronto tra Loss di Training e Validation durante il fine-tuning. Si nota chiaramente come, dopo il punto di minimo della validazione, il modello inizi a overfitting, degradando la capacità di generalizzazione.

B. Risultati

In questa sezione vengono presentati e analizzati i risultati ottenuti dalle diverse architetture neurali testate sul benchmark KUKA KR300. Le prestazioni sono state valutate in modalità *free-run simulation*, ovvero utilizzando le uscite predette dal modello come ingressi ricorsivi per i passi temporali successivi, rappresentando il test più severo per la stabilità di una rete ricorrente.

1) *Analisi dell'Identificazione Diretta* ($\tau \rightarrow q$): L'identificazione diretta rappresenta il task più complesso a causa dell'accumulo di errore ricorsivo che tende a far divergere la traiettoria stimata rispetto a quella reale. I risultati sono sintetizzati nella Tabella I.

Tabella I
RISULTATI IDENTIFICAZIONE DIRETTA ($\tau \rightarrow q$)

Architettura	Mean R^2 (%)	Max BFR (%)	NRMSE
Linear Baseline	31,14	-	-
RNN	19,33	10,83	0.89
GRU	50,44	29,89	0,70
NNARX	49,63	31,13	0.69

2) *Analisi dell'Identificazione Inversa* ($q \rightarrow \tau$): L'identificazione inversa, mirata alla stima delle coppie motrici partendo dalla cinematica, mostra risultati numericamente superiori, come riportato nella Tabella II.

Tabella II
RISULTATI IDENTIFICAZIONE INVERSA ($q \rightarrow \tau$)

Architettura	Mean R^2 (%)	Max BFR (%)	NRMSE
Linear Baseline	62,00	-	-
RNN	81,47	57,47	0.42
GRU	83,00	60,09	0.40
NNARX	84,59	62,15	0.38

C. Risultati della RNN

L'utilizzo dell' Architettura RNN, come ci si aspettava già teoricamente, ha evidenziato un netto calo prestazionale rispetto alle altre due architetture prese in considerazione.

La RNN, infatti, ha registrato le metriche peggiori: un BFR significativamente inferiore e un NRMSE elevato molto vicino all'1. Questo comportamento è dovuto ai limiti di questa architettura: tra cui il fenomeno, già citato nel capitolo precedente, del vanishing gradient, la difficoltà nell'approssimare efficacemente le non linearità e le discontinuità presenti nella dinamica del manipolatore. In conclusione, sebbene la RNN sia l'architettura più veloce da addestrare a livello computazionale, l'elevato errore registrato ne decreta l'inefficacia e l'inadeguatezza per l'identificazione di un sistema robotico complesso come il KUKA.

D. Risultati dell'architettura GRU

I riscontri sperimentali evidenziano come l'introduzione della rete GRU (*Gated Recurrent Unit*) consenta di superare i rigidi limiti della *Linear Baseline*. Quest'ultima, infatti, si attesta su prestazioni modeste ($R^2 = 31,14\%$ nel task diretto), confermando l'inadeguatezza dei modelli lineari nel catturare fenomeni dinamici complessi, intrinsecamente non lineari, quali l'attrito dissipativo e i giochi meccanici (*backlash*) delle giunzioni del manipolatore.

Nel task di **identificazione diretta** ($\tau \rightarrow q$), l'architettura GRU apporta un beneficio immediato, innalzando l'accuratezza media (R^2) sopra la soglia del 50%. Sebbene la rete risenta parzialmente dell'accumulo di errore tipico della modalità *free-run simulation*, i suoi meccanismi di *gating* interni (le porte di *reset* e di *update*) le consentono di filtrare il rumore e mantenere una stabilità della traiettoria predetta nettamente superiore rispetto a una RNN classica.

Le potenzialità della GRU emergono in modo ancora più evidente nel task di **identificazione inversa** ($q \rightarrow \tau$), dove l'architettura raggiunge un ottimo R^2 dell'83,00%. Questo marcato incremento prestazionale rispetto allo scenario diretto è riconducibile alla natura intrinseca del problema e alla stabilità dei segnali. Nell'identificazione inversa, infatti, le variabili cinematiche di ingresso (posizioni, velocità e accelerazioni) presentano un elevato contenuto informativo e sono fornite direttamente dal benchmark. Di conseguenza, la rete riesce a mappare in modo estremamente efficace e robusto la complessa relazione causale che lega lo stato cinematico alle coppie motrici necessarie per generarlo.

E. Risultati dell'architettura NNARX

A differenza dei modelli valutati in *one-step ahead*, il modello NNARX è stato testato in pura simulazione *Free-Run* per l'intero orizzonte temporale della finestra alimentando la cella GRU esclusivamente con le proprie predizioni passate. Questo ha portato a risultati ottimi per il task inverso, come evidenziato nella tabella II, grazie all'implementazione della tecnica di *Scheduled Sampling* durante la fase di addestramento. La rete, cioè, non è stata addestrata nè in un *Free-Run* immediato perchè porterebbe a un'esplosione dei gradienti a causa dell'errore accumulato usando subito le previsioni nè in puro *Teacher Forcing* usando solo i dati reali; ma la probabilità di fornire il dato reale passato è stata fatta decadere linearmente nel primo 30% delle epoche. Ciò ha permesso

ai pesi di stabilizzarsi, rendendo l'NNARX incredibilmente robusto all'accumulo di errore.

Tuttavia, l'architettura NNARX mostra un leggero peggioramento rispetto alla GRU nel task diretto perchè introduce un ciclo di feedback autoregressivo, concatenando l'uscita predetta al passo precedente (y_{t-1}) con l'ingresso esogeno attuale (u_t). La previsione non è precisa quindi il feedback amplifica l'errore. Invece, nel task inverso, la rete riceve in ingresso l'intero stato desiderato, quindi il feedback che propaga il segnale della coppia motrice stimata al passo precedente si rivela un vantaggio determinante.




Figura 6. Curve di apprendimento (Training e Validation Loss) del modello NNARX durante il task inverso.




Figura 7. Curve di apprendimento (Training e Validation Loss) del modello NNARX durante il task diretto.

La Figura 6 riporta l'andamento dell'errore durante l'addestramento del modello NNARX (Inverse Task), evidenziando l'effetto dello Scheduled Sampling e l'intervento dell'Early Stopping all'epoca 128. La Figura 7 riporta l'andamento dell'errore durante l'addestramento del modello NNARX (Inverse Task), evidenziando l'effetto dello Scheduled Sampling e l'intervento dell'Early Stopping all'epoca 65. Si nota una marcata asimmetria iniziale tra la curva di Training (blu) e quella di Validation (arancione) perchè nel training set la rete

beneficia dello *Scheduled Sampling* e avendo accesso parziale alle coordinate reali del passato, l'errore di training risulta basso fin dai primi istanti. Invece il Validation set è valutato in puro *Free-Run*, simulando interi blocchi da 12 secondi (120 passi). Raggiunto il 30% delle epoche totali prescritte dal decadimento lineare, la probabilità di Teacher Forcing si azzerava e in quel preciso istante, la curva di Training subisce un lieve innalzamento. La curva di Validation, crolla rapidamente verso il basso non appena la rete impara a stabilizzare il proprio ciclo autoregressivo, per poi appiattirsi in modo solido e costante.




Figura 8. Valutazione del modello a dinamica inversa per il Giunto 3 e il Giunto 4. Per ciascun giunto, il grafico superiore illustra la coppia di tracciamento reale (misurata) confrontata con le predizioni della rete GRU, mentre il grafico inferiore mostra la ricostruzione temporale dell'errore residuo di inseguimento ($\Delta\tau = \tau_{\text{true}} - \tau_{\text{pred}}$), evidenziando lo scostamento massimo assoluto (Max Err) registrato lungo la traiettoria di validazione.

V. CONCLUSIONI

In questo studio è stata presentata un'analisi comparativa approfondita per l'identificazione della dinamica non lineare del manipolatore industriale ad alto carico KUKA KR300, operando sul benchmark di riferimento in letteratura. L'approccio basato interamente sui dati (*black-box*) ha dimostrato di poter superare le intrinseche limitazioni dei modelli analitici tradizionali e delle baseline lineari, che non riescono a descrivere accuratamente i fenomeni dissipativi, gli effetti di *backlash* e le forti asimmetrie accoppiate del sistema robotico.

I risultati sperimentali indicano che la scelta dell'architettura neurale e la strategia di addestramento rivestono un ruolo cruciale a seconda del task identificato:

- Nel task di **dinamica diretta** ($\tau \rightarrow q$), la simulazione in puro *free-run* ha confermato la natura critica della divergenza ricorsiva dell'errore. Ciononostante, l'architettura GRU ha dimostrato una robustezza superiore rispetto alla RNN classica (afflitta da *vanishing gradient*), stabilizzando le traiettorie e innalzando l'accuratezza media

(R^2) oltre la soglia del 50%, riducendo contestualmente l'errore quadratico normalizzato ($NRMSE = 0,70$).

- Nel task di **dinamica inversa** ($q \rightarrow \tau$), le risposte numeriche sono state nettamente superiori per tutti i modelli deep grazie alla configurazione informativa stabile dei segnali d'ingresso (*one-step-ahead*). L'architettura NNARX, integrata con il protocollo di *Scheduled Sampling*, si è rivelata la più performante in assoluto in questo scenario, raggiungendo un coefficiente R^2 dell'84,59% e una robustezza ottimale all'accumulo di errore locale.

In conclusione, l'impiego sinergico di modelli a cancelli come le GRU e di strategie di regolarizzazione dinamica (quali *Early Stopping* e *Scheduled Sampling*) permette di mappare con elevata fedeltà lo stato cinematico e degli sforzi del manipolatore. Tali modelli gettano le basi per lo sviluppo di gemelli digitali in tempo reale e per l'implementazione di controllori industriali predittivi avanzati a coppia calcolata.

A. Lavori futuri

Sulla base delle evidenze sperimentali emerse, le traiettorie di ricerca future si orienteranno verso lo sviluppo di architetture neurali customizzate e disaccoppiate, capaci di indirizzare le specifiche criticità dei diversi macro-blocchi cinematici del manipolatore.

In particolare, i giunti appartenenti al polso sferico (Giunti 4, 5 e 6) presentano le maggiori sfide modellistiche a causa di severe non linearità geometriche, accoppiamenti dinamici ad alta frequenza e ridotte costanti di tempo inerziali. Per superare tali limiti, verranno indagati due approcci principali:

- **Assegnazione asimmetrica della capacità computazionale:** Progettazione di reti multi-branch in cui i sotto-modelli dedicati alla terna del polso siano caratterizzati da una dimensione dello stato latente (*hidden dimension*) superiore e da un maggior numero di neuroni nei livelli completamente connessi, garantendo un'adeguata ricchezza parametrica per l'approssimazione delle discontinuità.
- **Meccanismi di pesatura dinamica e attenzione:** Introduzione di funzioni di costo pesate (Loss Custom) che penalizzino in modo asimmetrico gli errori di inseguimento sui giunti più critici, oppure integrazione di moduli di attenzione spaziale e temporale (*Attention Mechanisms*) integrati nelle unità GRU. Tale framework permetterà alla rete di concentrare i gradienti e scalare i pesi sinaptici in funzione della complessità dinamica dell'asse accelerato.

RIFERIMENTI BIBLIOGRAFICI

- [1] J. Weigand et al., "Dataset and Baseline for an Industrial Robot Identification Benchmark", 2023.
- [2] K. Cho et al., "Learning Phrase Representations using RNN Encoder-Decoder," 2014.
- [3] I. Goodfellow, Y. Bengio, A. Courville, *Deep Learning*, MIT Press, 2016.
- [4] K. Cho, B. van Merriënboer, C. Gulcehre, D. Bahdanau, F. Bougares, H. Schwenk, and Y. Bengio, "Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation," in *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2014, pp. 1724–1734.